

UNIVERSIDADE FEDERAL DE VIÇOSA
CAMPUS VIÇOSA
CIÊNCIA DA COMPUTAÇÃO

GUTTARDO NÉRI PEREIRA

**PREDIÇÃO DE ENERGIA SOLAR COM MACHINE
LEARNING E IOT**

VIÇOSA
2018

GUTTARDO NÉRI PEREIRA

PREDIÇÃO DE ENERGIA SOLAR COM MACHINE LEARNING E
IOT

Monografia apresentada à Universidade Federal de Viçosa como parte das exigências para a aprovação na disciplina Projeto Final de Curso

Orientador: Ricardo Santos Ferreira

VIÇOSA

2018

Resumo

Esse projeto de pesquisa tem como propósito prever a geração de energia solar em uma estação situada no Departamento de Engenharia Elétrica da UFV. Para isso a ideia é aplicar métodos de aprendizagem de máquina utilizando dados coletados por sensores em um Arduino durante um longo período. Seguindo na mesma linha, um segundo propósito é através de sensores LDRs de baixo custo obter uma relação de mapeamento com um piranômetro, equipamento de alto custo usado para medição de irradiação solar. Até o momento já temos um banco de dados para a persistência dos dados dos sensores e uma interface WEB em um ambiente Node-Red para visualização dos dados coletados. O protótipo para a coleta está em fase final de construção.

Palavras-chaves: Solar, IoT, Arduino, Aprendizagem, UFV.

Abstract

This research project aims to predict the generation of solar energy in a station located in the Department of Electrical Engineering of the UFV. For this the idea is to apply machine learning methods using data collected by sensors in an Arduino during a long period. Following in the same line, a second purpose is through low-cost LDR sensors to obtain a mapping relationship with a pyranometer, a high-cost equipment used for measuring solar irradiation. So far we have a database for the persistence of sensor data and a WEB interface in a Node-Red environment to view the collected data. The prototype for the collection is in the final stage of construction.

Key-words: Solar, IoT, Arduino, Learning, UFV

Lista de ilustrações

Figura 1 – Objetivo Geral	7
Figura 2 – LDRs	8
Figura 3 – Node-RED	13
Figura 4 – WEB API	14
Figura 5 – WEB Sensores	14

Lista de tabelas

Tabela 1 – Cronograma	15
---------------------------------	----

Sumário

1	Introdução	7
1.1	Objetivo Geral	7
1.2	Objetivos Específicos	8
2	Referencial Teórico	9
3	Trabalhos Relacionados	10
3.1	Previsão de 24 horas de irradiação solar usando redes neurais artificiais	10
3.2	Machine Learning para previsão de radiação solar	10
3.3	Uma nova abordagem adaptativa para previsão de radiação solar por hora	10
4	Metodologia e Cronograma	11
4.1	Sensores	11
4.1.1	LDR	11
4.1.2	BMP180	11
4.1.3	BH1750	11
4.1.4	TSL2561	11
4.2	Arduino	12
4.3	NodeMCU	12
4.4	MQTT	12
4.5	Node-RED	12
4.6	API de Metereologia	13
4.7	Interface WEB	13
4.8	Cronograma	15
5	Resultados Esperados	16
	Referências	17

1 Introdução

A energia solar é inesgotável do ponto de vista humano, e seu potencial é excepcionalmente maior em comparação a outras fontes de energia. A utilização de métodos para a previsão de geração de energia em uma placa solar é de suma importância para o mercado. Empresas de energia elétrica precisam de previsões precisas da produção de energia para ter o equilíbrio certo de combustíveis renováveis e fósseis disponíveis. Erros na previsão podem levar a grandes despesas para a concessionária por excesso de consumo de combustível ou compras emergenciais de eletricidade de concessionárias vizinhas. Ideias de baixo custo são necessárias para que seja viável a utilização fazendo que o ganho em geração seja maior que o investimento. Projetos envolvendo internet das coisas, em específico na plataforma Arduino, tem justamente essa vantagem.

Arduino é uma plataforma de prototipagem eletrônica amplamente usada no mundo todo. Por sua facilidade de implementação e seu baixo custo, é uma ótima escolha para projetos de IoT. Neste projeto o Arduino será usado para realizar leituras de vários sensores (iluminosidade, temperatura, etc).

A aprendizagem de máquina, ou Machine Learning como conhecido globalmente, é uma vertente da Inteligência Artificial que em resumo se baseia na ideia de que sistemas podem aprender com dados, identificar padrões e tomar decisões com o mínimo de intervenção humana.

1.1 Objetivo Geral

O foco principal dessa pesquisa é criar um sistema que una Internet da Coisas e Inteligência Artificial para prever com uma boa aproximação a quantidade de energia fotovoltaica que uma placa situada na UFV irá gerar. Utilizar aprendizagem de máquina para fazer previsões de geração de energia solar já é algo explorado. Existe até mesmo uma competição internacional que premia equipes que desenvolvam um método de aprendizagem mais preciso para predição.



Figura 1 –

1.2 Objetivos Específicos

Essa pesquisa segue em linha com um projeto do Professor Heverton Pereira, do Departamento de Engenharia Elétrica da UFV. Outro objetivo que também será buscado, atendendo as demandas do Professor, é o de relacionar leituras de vários LDRs ligados em diferentes resistências com os dados de um piranômetro.

O LDR é um fotoresistor de baixíssimo custo. Um fotoresistor é basicamente um resistor cuja resistência varia conforme a intensidade da luz que incide sobre ele. Um grande problema ao utilizar o LDR é sua faixa de medição, que conforme menor resistência, menor a intensidade de luz que ele consegue medir e quando aumenta-se sua resistência, intensidade menores de iluminação não são detectadas. A ideia então é criar uma rede de LDRs ligados a diferentes resistências, para que então seja possível realizar leituras, sem saturação, durante um dia inteiro. Junto a isso, tentar obter uma função de mapeamento, que terá como atributos as leituras dos LDRs e resultado a leitura, ou algo aproximado, do piranômetro, sensor de irradiação solar de alto custo.




Figura 2 –

2 Referencial Teórico

“Se tivéssemos computadores que soubessem tudo sobre as coisas em geral – usando dados que coletassem sem a nossa ajuda – seríamos capazes de rastrear e contar tudo, e reduzir bastante o desperdício, a perda e os custos. Nós saberíamos quando é necessário substituir, reparar ou fazer um recall de um produto, e se estão novos ou ultrapassados. Precisamos capacitar os computadores com seus próprios meios de coletar informações, para que possam ver, ouvir e cheirar o mundo sozinhos, com toda a sua glória aleatória. O RFID e a tecnologia de sensores capacitam os computadores a observar, identificar e entender o mundo sem as limitações dos dados inseridos pelos humanos”(ASHTON, 1999). Na época em que Kevin disse isso, essa visão exigia grandes melhorias na tecnologia. Afinal, como conectaríamos tudo no planeta? Que tipo de comunicação sem fio poderia ser usada? Quais alterações precisariam ser feitas na Internet para comportar bilhões de dispositivos se comunicando? Hoje em dia a IoT é real e o cada vez mais tudo está se conectando, está ficando "inteligente".

"As previsões de energia são tipicamente derivadas de modelos numéricos de previsão do tempo, mas as técnicas estatísticas e de aprendizado de máquina estão sendo cada vez mais usadas em conjunto com os modelos numéricos para produzir previsões mais precisas"(AMS, 2013). Uma das motivações passadas na competição para predição de energia solar é que as previsões sempre são derivadas de modelos numéricos, que demandam de grande poder computacional. O mundo da inteligência artificial está cada vez mais dentro desse contexto.

3 Trabalhos Relacionados

Ao pesquisar sobre trabalhos relacionados, foram indentificados vários artigos que mostram resultado do uso da Inteligência Artificial para predição de geração de energia solar.

3.1 Previsão de 24 horas de irradiação solar usando redes neurais artificiais

A proposta nessa pesquisa é quase a mesma, mas aqui ele utiliza RNAs para previsão, mais especificamente o modelo MLP(Multilayer Perceptron). O modelo se baseia em dados atuais de irradiação solar média e temperatura do ar para predizer a irradiação para as próximas 24 horas. Obteve bons resultados, com coeficientes de correlação de até 99% em dias ensolarados. Vale ressaltar que eles obtiveram a previsão de irradiação solar e não da produção de energia solar.([MELLIT, 2011](#))

3.2 Machine Learning para previsão de radiação solar

Cyril Voyant faz aqui o uso de Machine Learning para predição de radiação. Sua pesquisa se embasa mais em comparação de métodos. Um dado importante e que será usado também nesse projeto é a sazonalidade dos dados. Utilizar dados de alguns meses atrás não ajuda muito nesse contexto pela questão de inclinação da terra, que resulta em estações diferentes. O ideal é utilizar dados pertencentes ao mesmo ano para traçar padrões para aquele mesmo intervalo em anos posteriores.([VOYANT, 2017](#))

3.3 Uma nova abordagem adaptativa para previsão de radiação solar por hora

Nesse artigo foi utilizada uma metodologia de duas estratégias para obter um previsão de radiação solar. A primeira decide o método de predição de acordo com a estação. Verão e inverno utiliza-se de métodos lineares devidos as raras alterações por curtos períodos de tempo. Já no outono e primavera, que alterações maiores são mais prováveis, utiliza-se de um método empírico que a partir do índice de clareza para selecionar o método de predição. É uma abordagem interessante, que novamente ressalta que a sazonalidade dos dados deve ser levada em conta. ([AKARSLAN; HOCAOGLU, 2016](#))

4 Metodologia e Cronograma

Durante esse semestre a pesquisa se voltou para o lado da prototipação do sistema de realização de leitura dos sensores. Os processos de implementação e os materiais utilizados serão descritos a seguir.

4.1 Sensores

Foram selecionados sensores de iluminação e temperatura. Atualmente utiliza-se 3 LDRs, 1 TSL2561, 1 BMP180 e 1 BH1750.

4.1.1 LDR

Como já descrito, o LDR é um foto resistor, ou seja, um resistor que sua resistência varia de acordo com a incidência de iluminação sobre ele. Em sua utilização normal, o LDR é montado num circuito onde a resistência é convertida para tensão. É um sensor de baixíssimo custo e facilidade de utilização. Por este motivo é encontrado em praticamente todas aplicações do dia-a-dia, como medidores de luz, detectores de incêndio, controles de iluminação, etc.([REIS, 2016](#))

4.1.2 BMP180

O BMP180 é um sensor de temperatura e pressão atmosférica. É um sensor compacto e de baixo consumo. Já vem calibrado de fábrica e funciona na interface I2C. O I2C é um barramento serial que permite a conexão de até 112 dispositivos em uma única comunicação([RODRIGUES, 2014](#)). É extremamente útil, pois o Arduíno tem poucas entradas. I2C facilita também o processo de conexão e configuração de um novo sensor.([THOMSEN, 2015](#))

4.1.3 BH1750

O BH1750 é um sensor digital para determinar a quantidade de iluminação, medida em lux, que está incidindo sobre o sensor. Também tem a interface I2C, facilitando seu uso.([MINATEL, 2017](#))

4.1.4 TSL2561

O TSL2561 é também um sensor de iluminação, porém, muito mais preciso que os LDRs. Se trata de um sensor digital e pode ser configurado para diferentes níveis de de-

tecção, de 0-40000 lux. O diferencial deste sensor é que vem embutido diodos que medem o espectro completo e infravermelho, com isso é possível medição separada da luz infravermelha, espectro completo ou luz visível ao olho humano ([TSL2561...](#), 2009). A maioria dos outros sensores detecta somente um ou outro espectro. Além disso o sensor também tem interface I2C, o que diminui a complexidade do circuito e facilita a implementação para a leitura. ([TSL2561...](#), 2009)

4.2 Arduino

O Arduino é o microcontrolador que recebe os dados digitais e analógicos dos sensores. Nesse projeto o Arduino usado é o UNO. Os sensores LDRs retornam uma saída analógica entre 0 e 1024. Os outros se comunicam na interface I2C. O Arduino reserva as portas analógicas A4 e A5 para o I2C, sendo a porta A4 a de dados seriais(SDA) e a A5 a de clock serial(SCL). ([ARDUINO](#),)

4.3 NodeMCU

O NodeMCU é também um microcontrolador que tem embutido o chip ESP8266, que é um módulo WiFi. O NodeMCU tem a função aqui de receber via porta serial os dados lidos pelo Arduino e mandar para o banco de dados essas leituras. Atualmente o NodeMCU está sendo deixado de lado no projeto. Com alguns testes no DPI pôde-se observar que pela latência grande da rede local, criava-se uma fila em sua porta serial, o que causava inconsistência nos dados. A nova alternativa agora será utilizar um Raspberry Pi, que já é um computador, com sistema operacional. A persistência ficará mais simples assim, podendo ser feito um banco de dados local que sincroniza diariamente com o servidor. ([MORAIS](#), 2017)

4.4 MQTT

O MQTT é um protocolo de rede para envio e recebimento de mensagens muito comumente usado em intert das coisas. Por ser leve e otimizado para redes TCP/IP não confiáveis ou de alta latência, o MQTT é a melhor escolha para a transmissão de dados de leitura dos sensores. É através do MQTT que os dados de cada sensor está sendo enviado para o servidor. ([YUAN](#), 2017)

4.5 Node-RED

O Node-RED é uma ferramenta para criação de aplicações WEB muito usada no contexto de IoT. Ele se baseia no modelo de programação gráfica, ou seja, através do

mesmo, torna-se possível elaborar uma aplicação por meio do estabelecimento de conexões entre blocos que possuem códigos predefinidos (conhecidos como nós) para a realização de determinadas tarefas. (MADEIRA, 2017)

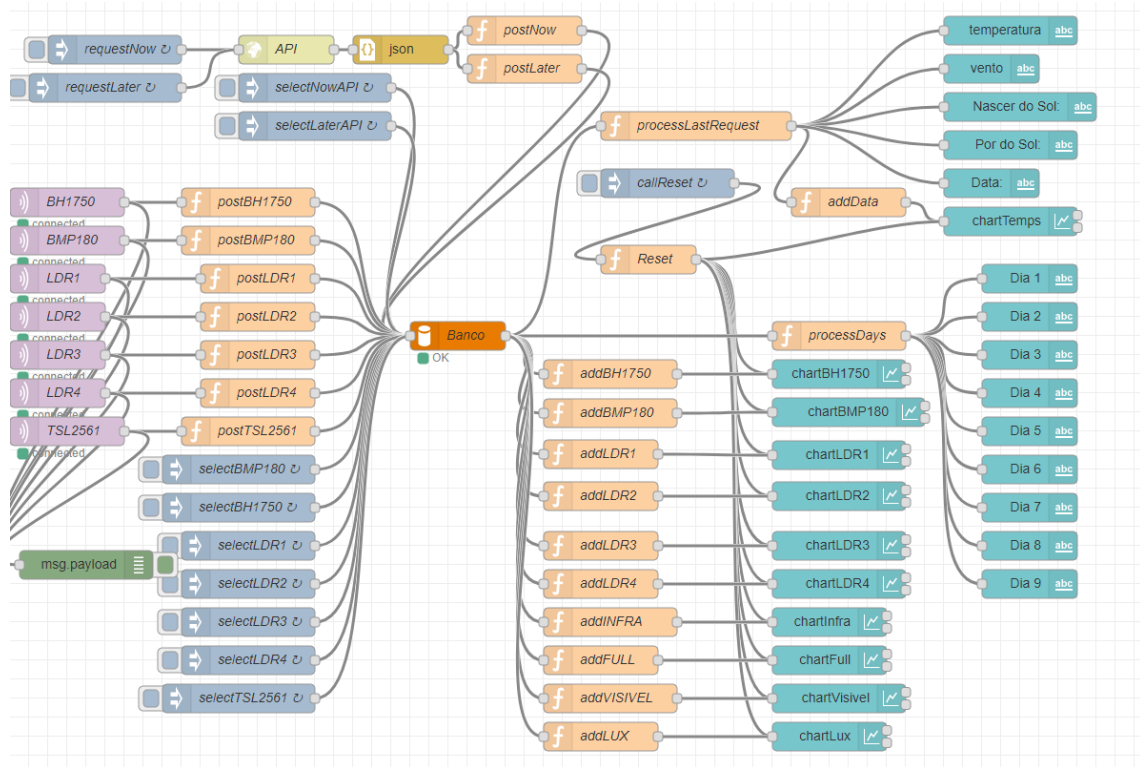


Figura 3 – Esquema do projeto de interface WEB e persistência de dados no Node-RED

4.6 API de Metereologia

Para agregar mais dados para aprendizagem e efeitos de comparação com dados dos sensores, foi escolhida uma API de dados metereológicos. O servidor faz requisições diárias para obter dados de min e max para os próximos 10 dias e requisições de hora em hora para dados atuais de temperatura, velocidade do vento, umidade, etc. A API escolhida foi a HG Weather, que é gratuita e retorna uma grande gama de dados.

4.7 Interface WEB

Uma interface para a visualização das leituras dos sensores e da API foi elaborada. Nela é mostrado os dados recebidos pela API e também os dados em forma de gráfico das leituras nos sensores.

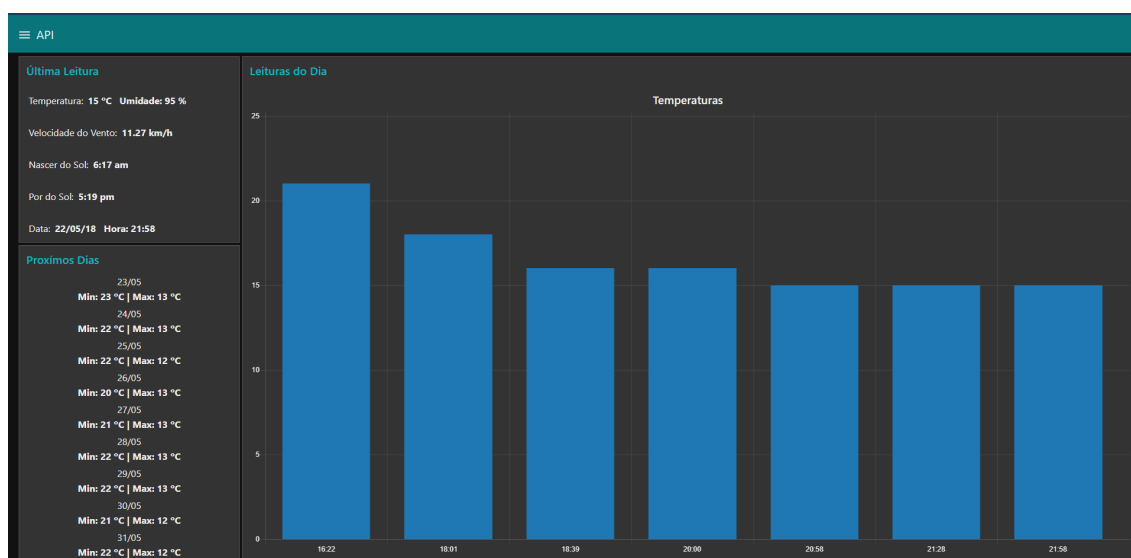


Figura 4 – Apresentação dos dados recebidos pela API

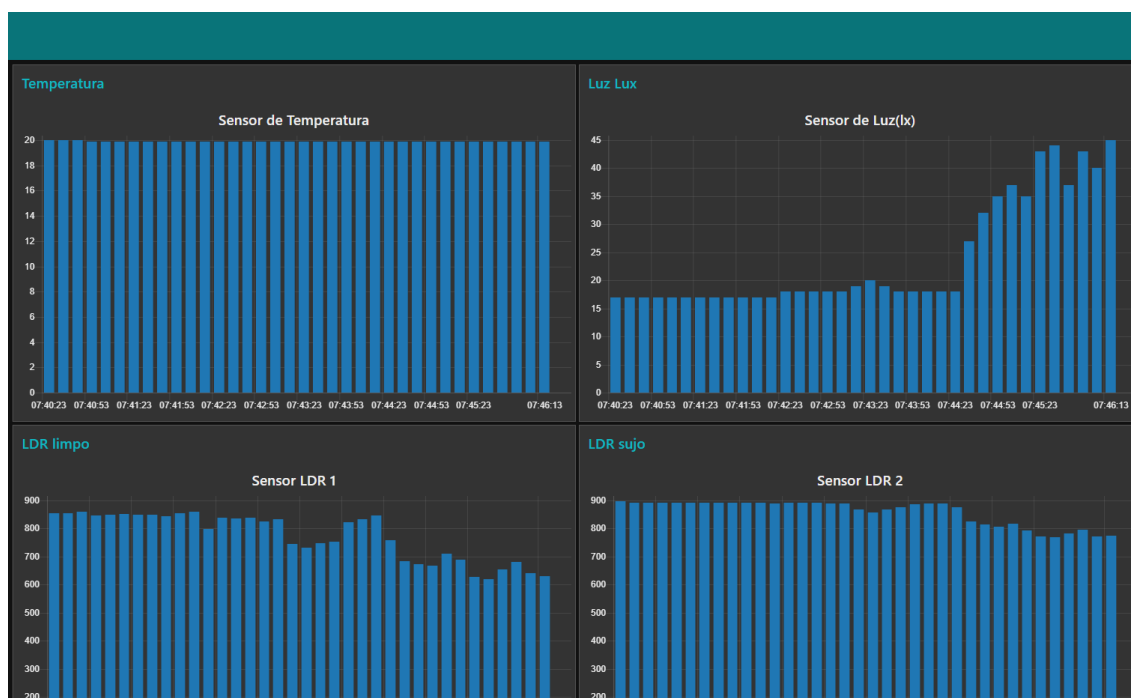


Figura 5 – Apresentação dos dados lidos nos sensores

5 Resultados Esperados

Ainda não é possível dizer com precisão os resultados. A ideia mais simples é aplicar os métodos lineares e buscar padrões para previsões de horas ou dias. Pelo tempo curto não será possível explorar atributos que aumentariam a precisão e intervalo de previsão, como recursos de visão computacional, estudo de estações, entre outros.

Referências

- AKARSLAN, E.; HOCAOGLU, F. O. A novel adaptive approach for hourly solar radiation forecasting. **Elsevier Renewable Energy**, v. 87, p. 628–633, 2016.
- AMS. **AMS 2013-2014 Solar Energy Prediction Contest**. 2013. Disponível em: <<https://www.kaggle.com/c/ams-2014-solar-energy-prediction-contest>>. Acesso em: 12 jul. 2018.
- ARDUINO. Disponível em: <<https://www.arduino.cc/en/Guide/Introduction>>. Acesso em: 13 jul. 2018.
- ASHTON, K. **That 'Internet of Things' Thing**. 1999. RFID Journal.
- MADEIRA, D. **Primeiros passos com o Node-RED e Arduino UNO**. 2017. Disponível em: <<https://www.filipeflop.com/blog/primeiros-passos-node-red-arduino-uno/>>. Acesso em: 13 jul. 2018.
- MELLIT, A. A 24-h forecast of solar irradiance using artificial neural network: Application for performance prediction of a grid-connected pv plant at trieste, italy. **Elsevier Solar Energy**, v. 85, p. 2856–2870, 2011.
- MINATEL, P. **Como funciona o sensor de luz BH1750**. 2017. Disponível em: <<https://imasters.com.br/desenvolvimento/como-funciona-o-sensor-de-luz-bh1750>>. Acesso em: 13 jul. 2018.
- MORAIS, J. **O que é ESP8266 – A Família ESP e o NodeMCU**. 2017. Disponível em: <<https://portal.vidadesilicio.com.br/o-que-esp8266-nodemcu/>>. Acesso em: 13 jul. 2018.
- REIS, F. **O que é um LDR (Light Dependent Resistor)**. 2016. Disponível em: <<http://www.bosontreinamentos.com.br/eletronica/curso-de-eletronica/curso-de-eletronica-o-que-e-um-ldr-light-dependent-resistor/>>. Acesso em: 13 jul. 2018.
- RODRIGUES, V. **I2C – Protocolo de Comunicação**. 2014. Disponível em: <<http://www.arduino.br/arduino/i2c-protocolo-de-comunicacao/>>. Acesso em: 12 jul. 2018.
- THOMSEN, A. **Controlando temperatura e pressão com o BMP180**. 2015. Disponível em: <<https://www.filipeflop.com/blog/temperatura-pressao-bmp180-arduino/>>. Acesso em: 13 jul. 2018.
- TSL2561 Datasheet. 2009. Disponível em: <<https://cdn-shop.adafruit.com/datasheets/TSL2561.pdf>>. Acesso em: 12 jul. 2018.
- VOYANT, C. Machine learning methods for solar radiation forecasting: A review. **Elsevier Renewable Energy**, v. 105, p. 569–582, 2017.
- YUAN, M. **Conhecendo o MQTT**. 2017. Disponível em: <<https://www.ibm.com/developerworks/br/library/iot-mqtt-why-good-for-iot/index.html>>. Acesso em: 13 jul. 2018.